

Exercice : Nettoyage et analyse des ventes d'une boutique

Niveau : debutant / intermediaire — Fichier associe : ventes_boutique.csv

Contexte

Vous travaillez pour une petite boutique de vetements au Togo. On vous transmet un export brut des commandes de l'annee 2024 (490 lignes). Ce fichier n'a jamais ete nettoye : il contient des doublons, des valeurs manquantes, des textes mal ecrits (majuscules, espaces en trop) et des dates dans deux formats differents. Votre mission : nettoyer ce fichier puis en tirer des conclusions chiffrees et visuelles pour la direction.

Description des colonnes

- **id_commande** — Identifiant unique de la commande
- **date_commande** — Date de la commande (attention, deux formats coexistent)
- **client_id** — Identifiant du client
- **ville_client** — Ville du client (quelques valeurs manquantes)
- **produit** — Nom du produit achete (casse/espaces incoherents)
- **categorie** — Categorie du produit (Haut, Bas, Chaussures, Accessoire)
- **quantite** — Quantite commandee (quelques valeurs manquantes)
- **prix_unitaire** — Prix unitaire en euros (valeurs manquantes + quelques outliers)
- **note_satisfaction** — Note du client de 1 a 5 (beaucoup de valeurs manquantes)

Partie 1 — Exploration

- 1.1. Chargez le fichier avec pandas et affichez sa forme (nombre de lignes / colonnes).
- 1.2. Affichez les informations generales du DataFrame (types, valeurs non nulles).
- 1.3. Comptez le nombre de valeurs manquantes par colonne.
- 1.4. Comptez le nombre de lignes en double (attention : dupliquees a l'identique).

Partie 2 — Nettoyage

- 2.1. Supprimez les lignes strictement dupliquees.
- 2.2. Nettoyez la colonne **produit** : supprimez les espaces inutiles et harmonisez la casse (par exemple tout mettre avec une majuscule initiale). Utilisez les methodes `.str` de pandas (`.str.strip()`, `.str.title()`, `.str.replace()`).
- 2.3. La colonne **date_commande** contient deux formats de date (AAAA-MM-JJ et JJ/MM/AAAA). Convertissez toute la colonne en un vrai type datetime avec `pd.to_datetime` en gerant ce melange de formats.
- 2.4. Traitez les valeurs manquantes de **prix_unitaire** en les remplaçant par la mediane du produit concerne (pas la mediane globale : utilisez un groupby + transform, ou une boucle simple si vous preferez).
- 2.5. Traitez les valeurs manquantes de **quantite** en les remplaçant par 1 (hypothese : une commande sans quantite renseignee correspond a 1 article).
- 2.6. Traitez les valeurs manquantes de **ville_client** en les remplaçant par la chaine "Inconnue".

2.7. Detectez les valeurs aberrantes (outliers) de **prix_unitaire** : un prix supérieur à 300€ n'a pas de sens pour cette boutique. Affichez ces lignes, puis remplacez ces valeurs par la médiane du produit concerné (même logique qu'en 2.4).

2.8. La colonne **note_satisfaction** garde volontairement ses valeurs manquantes (on ne remplace pas une note qui n'a pas été donnée). Vous vous en servirez telle quelle.

Partie 3 — Enrichissement et agrégations

3.1. Créez une colonne **montant_total** = quantité × prix_unitaire.

3.2. À partir de **date_commande**, créez deux nouvelles colonnes : **mois** (numéro du mois) et **jour_semaine** (nom du jour), en utilisant l'accessoire `.dt`.

3.3. Calculez le chiffre d'affaires total (somme de **montant_total**) par catégorie de produit, trié du plus grand au plus petit.

3.4. Calculez le chiffre d'affaires total par mois.

3.5. Calculez, pour chaque produit, la quantité moyenne commandée et la note de satisfaction moyenne (utilisez `.agg()`).

3.6. Construisez un tableau croisé (**pivot_table**) montrant le chiffre d'affaires total par ville et par catégorie.

3.7. Identifiez le top 5 des clients (**client_id**) par montant total dépense.

Partie 4 — Visualisation (nouveau : matplotlib)

Jusqu'ici vous avez manipulé des tableaux de chiffres. Il est temps de les transformer en graphiques avec la bibliothèque **matplotlib**, l'outil de référence pour visualiser des données en Python. Le principe de base est toujours le même :

```
import matplotlib.pyplot as plt
```

```
plt.figure(figsize=(8, 5))
plt.plot(x, y)          # ou plt.bar(x, y) pour un graphique en barres
plt.title("Mon titre")
plt.xlabel("Axe X")
plt.ylabel("Axe Y")
plt.show()
```

`plt.plot()` trace une courbe (utile pour une évolution dans le temps), `plt.bar()` trace un diagramme en barres (utile pour comparer des catégories).

À faire :

4.1. Tracez la courbe (`plt.plot`) du chiffre d'affaires total par mois (mois en abscisse, CA en ordonnée). N'oubliez pas titre et labels des axes.

4.2. Tracez un diagramme en barres (`plt.bar`) du chiffre d'affaires total par catégorie de produit.

4.3. Tracez un diagramme en barres du nombre de commandes par ville (hors "Inconnue").

4.4. Bonus : sur une même figure, superposez deux courbes représentant le CA mensuel de deux catégories différentes, avec une légende (`plt.legend()`).

Partie 5 — Conclusions

Rédigez en quelques phrases les 3 à 5 conclusions principales que vous tirez de vos analyses (produit ou catégorie qui génère le plus de CA, ville la plus active, mois le plus fort, satisfaction moyenne par produit, etc.).